ЛР 1. Прогноз результата LinkedIn-поста

Ростислав Манзюк, grinchaus
Social Media Analytics, Agents & LLMs, ИТМО

Задача и результат

Нужно определить, сработает ли пост хуже обычного результата своего автора, примерно так же или лучше. Классы - "below", "typical" и "above". Обычный уровень - медиана log(1 + reactions) по более ранним собственным постам автора, которых должно быть хотя бы пять. Основная метрика - macro-F1.

В этом раунде цель была приблизиться к macro-F1 0.70. Итог на официальном test - **0.6708**, предыдущая локальная версия - 0.6593. До порога 0.70 осталось 0.0292.

Данные и схема проверки

Взял официальный релиз Kairos: 71,395 размеченных постов от 3,295 авторов в train и 17,623 постов от 824 авторов в test. Разметка полностью воспроизводится штатным kairos.label. Авторы между train и test не пересекаются.

Новые подходы выбирал на двух разбиениях train по авторам: seed 42 и 137, по 20% авторов для валидации. PCA, словари, масштабирование и графовая статистика обучаются только на fit. Веса смешивания и поправки классов общие для двух разбиений. Разрешил не больше трёх добавлений в ансамбль, каждое с приростом среднего macro-F1 хотя бы 0.0004. На каждом разбиении результат должен сохраняться не ниже фиксированной предыдущей версии.

После выбора зафиксировал конфигурацию и отдельно проверил её на отложенных авторах с seed 2026. По этой проверке настройки уже не менял. Разбиения частично пересекаются, поэтому их оценки нельзя считать независимыми. Официальный test оценивался в предыдущих версиях работы; в этом раунде его повторная оценка выполнена после фиксации всех настроек.

Что добавил и проверил

Сохранил предыдущий ансамбль CatBoost, TF-IDF и небольшой нейросети на multilingual E5-small. Он использует содержание поста, профиль, историю реакций и сходство с более ранними постами автора. В своей предобработке также сохранил исправление смешанных ISO-форматов дат, которое восстановило 8 185 дат сбора. Исходный baseline запускается без изменений.

В новых признаках исправил чтение размеров изображений: раньше выбиралось поле с вложенными списками, из-за чего размеры оставались нулевыми. Добавил форму и площадь изображений, историю результатов для такого же формата поста и повторных упоминаний, временные окна 7, 30, 90 и 365 дней, квантили предыдущих реакций и историю комментариев, репостов и типов реакций.

Проверил три постановки для CatBoost: обычные три класса, две бинарные задачи для границ классов и регрессию отклонения от обычного уровня автора. Для регрессии и бинарных моделей привёл вероятности к общей шкале с учётом частот классов на fit. Затем сравнил их вклад в ансамбль.

Для истории текста дополнительно проверил ядровую регрессию по предыдущим постам того же автора. Она даёт оценку ожидаемого отклонения и неопределённости с учётом сходства текстов. Текущий пост и более поздние реакции в эту историю не входят.

Проверил граф упоминаний людей и компаний и общих работодателей. Графовая статистика строится по fit-авторам. Для обучающего поста полностью вычитается вклад его автора, для validation его целевые значения вообще не читаются. Отдельно проверил TF-IDF по кодам упоминаний.

Дополнительно проверил фиксированный encoder Qwen3-Embedding-0.6B. Использовал инструкцию задачи, ограничение 1024 токена, вектор последнего действительного токена и L2-нормализацию. По этим векторам проверил CatBoost и небольшую нейросеть с историей автора. Все тексты обрабатывались локально. Во внешние API данные не отправлялись.

Также проверил сами изображения: по одному изображению, обложке или кадру видео на пост. Для GIF использовал первый кадр. Локальный CLIP ViT-B/32 дал векторы размерности 512. Добавил их PCA-представление, сходство с подписью и примерами типов контента, а также результаты похожих более ранних изображений автора. Визуальные варианты сравнил отдельно и вместе с Qwen. Все выбранные файлы проверены по SHA-256, изображения во внешние API не отправлялись.

Результаты выбора на train

Подход с общей калибровкой	Val 42 F1	Val 137 F1
Предыдущий ансамбль	0.6766	0.6729
Расширенные признаки	0.6715	0.6683
Две границы классов	0.6723	0.6712
Регрессия отклонения	0.6754	0.6684
Ядровая история	0.6745	0.6690
TF-IDF + упоминания	0.6461	0.6415
Графовая статистика	0.6735	0.6685
Изображения + CatBoost	0.6744	0.6722
Qwen + изображения	0.6787	0.6718
Qwen + CatBoost, depth 6	0.6758	0.6700
Qwen + CatBoost, depth 7	0.6752	0.6703
Qwen + нейросеть	0.6505	0.6553
Qwen + нейросеть, seed 2	0.6528	0.6553
Qwen + две нейросети	0.6586	0.6589
Нейросеть: Qwen + CLIP	0.6626	0.6572
Выбранный ансамбль	0.6866	0.6818

Эти оценки использовались для выбора модели и могут быть оптимистичными. Таблица сравнивает подходы целиком; вклад каждого отдельного признака здесь не выделял.

Дополнительная проверка, seed 2026	Macro-F1	QWK	Accuracy
Предыдущая версия	0.6611	0.6088	0.6924
Фиксированный новый ансамбль	0.6731	0.6237	0.7059

В дополнительной проверке 659 авторов и 14,161 постов. Настройки до её запуска уже были зафиксированы.

Итог на официальном test

Модель	Macro-F1	QWK	Accuracy
Исходный baseline	0.5403	0.4603	0.5445
Предыдущая локальная версия	0.6593	0.6018	0.6916
Выбранный новый ансамбль	0.6708	0.6175	0.7059

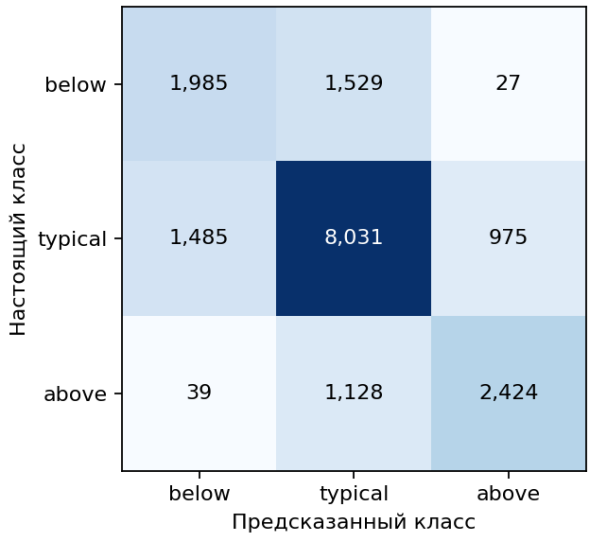
Прирост к предыдущей версии - +0.0115 macro-F1. 95% парный интервал разницы по авторам - [+0.0073; +0.0159]. 95% интервал итогового macro-F1 - [0.6616; 0.6802]. Использовал bootstrap по авторам, 2000 повторов: посты одного автора остаются вместе.

В README исходного проекта указан baseline 0.5410. Здесь использую результат его отдельного запуска в этом окружении - 0.5403.

Компонент итогового ансамбля	Вес
Предыдущий ансамбль	0.432
Регрессия отклонения	0.388
Нейросеть: Qwen + CLIP	0.180

Множители вероятностей классов: [0.65, 1.0, 0.6]. Число итераций и эпох для полного обучения зафиксировано по медиане выбранных значений на двух валидациях. Все параметры, версии encoder и отпечатки исходников сохранены в selection.json.

Класс	Precision	Recall	F1	Постов
below	0.5657	0.5606	0.5631	3541
typical	0.7514	0.7655	0.7584	10491
above	0.7075	0.6750	0.6909	3591



Ограничения и воспроизведение

Реакции текущего поста, его label и residual не входят в признаки для прогноза. В собственной истории используются только более ранние посты. Реакции прошлого поста при этом известны на момент сбора данных, как в официальном baseline. Изменение текущих и будущих реакций не меняет признаки текущего поста - это проверяется тестами.

Число подписчиков, профиль и возраст поста относятся к снимку на момент сбора. Поэтому это оценка для офлайн-задания. Она не обещает такой же результат сразу при публикации нового поста. В графе используются обезличенные коды общих сущностей. В визуальном эксперименте использованы изображения и отдельные кадры; движение и звук видео не обрабатывались.

Python 3.9.6. Кодирование текстов выполняется отдельно от обучения. Для чистого запуска нужны официальный распакованный набор и зависимости из requirements-embeddings.txt. Зафиксированную конфигурацию воспроизводит команда:

Тяжёлые этапы выполняются последовательно с низким приоритетом CPU и контролем памяти. Матрицы нейросети хранятся на диске, на GPU передаются отдельные батчи. При полном переобучении на другом оборудовании возможны небольшие численные отличия; повторный прогноз из сохранённой модели проверяется на точное совпадение CSV.

```
python run_lab1_v3.py --data data
```

Команда готовит недостающие локальные эмбеддинги, обучает модели с фиксированными настройками, выполняет дополнительную проверку и оценивает полный test. После сохранения модели отдельный запуск predict_lab1_v3.py обязан дать тот же CSV. В комплекте лежат выполненный notebook, отчёт, предсказания и метрики. Данные, пароли и веса моделей в Git не добавлены.

Источники: официальный baseline, Kairos, multilingual E5-small, Qwen3-Embedding-0.6B, CLIP ViT-B/32, уточнения из чата курса.